

从 mPL 到 Shapley 归因： 图像逐线索位置隐私泄露的量化

技术备忘 — GeoBayes 项目
Xinpeng Xie • 2026 年 7 月 17 日

摘要 一张照片会通过多种视觉线索泄露其拍摄地点。本文在给定具体攻击者的前提下, 量化**每条线索各泄露了多少位置信息**。线索子集的泄露由 mPL(距离归一化的后验泄露度量)度量。由于遮蔽效应不可加(线索之间存在信息重叠或互为备份), 单线索 mPL 是有偏的逐线索估计; 为此我们将泄露视为定义在线索子集上的集合函数, 并用 Shapley 值进行归因——其效率公理保证各线索份额之和恰等于已识别线索集的可移除总泄露。整套管线(GPT-4o 线索命名、SAM 3 掩码、GeoRanker 攻击者)在 100 张 im2gps3k 图像上完成评估。

1 问题描述

设图像 I 含 m 条已识别线索 $N = \{1, \dots, m\}$, 每条具有像素级掩码; 攻击者在固定候选集上形成后验分布。本文回答两个问题: 遮蔽任一线索子集会造成多大的信念移动(度量, § 2); 当各线索的效应不可加时, 总泄露应如何在线索之间分配(归因, § 4)。

2 隐私准则与攻击者模型

2.1 基本设定

设 $X \in \mathcal{X}$ 为图像 I 的拍摄地点, 其中 (X, d_X) 是候选地点构成的有有限度量空间, d_X 取 haversine 距离。我们以 im2gps3k 子集的 $n = 138$ 个城市级真值标签实例化 X (2 km 内的行政别名合并——仅 City of Westminster / Greater London, 相距 1.3 km——合并后余 137 个点; 真实相异的近邻地点一律保留不并)。对线索子集 $S \subseteq N$, 遮蔽图像 $I \ominus S$ ——将 S 中各线索的 SAM 3 掩码并集涂灰——充当“脱敏发布”。

攻击者模型 下述准则与具体攻击者无关; 经验审计时, 我们将攻击者实例化为带评分函数 $s_\theta(x; I)$ 的神经后验估计器——GeoRanker 奖励模型(Qwen2-VL-7B + LoRA + 价值头), 其得分随画面场景与候选 x 的地理接近度增大。对全部候选的得分做 softmax 得到归一化对抗信念(不称其为校准贝叶斯后验, 见 § 2.3; $\tau = 1$, 固定输入下确定):

$$\Pr_\theta(X = x_i | I) = \frac{\exp(s_\theta(x_i; I)/\tau)}{\sum_{x' \in \mathcal{X}} \exp(s_\theta(x'; I)/\tau)}, \quad x_i \in \mathcal{X} \quad (1)$$

2.2 度量归一化后验泄露(mPL)

定义 2.1 (mPL, 沿用 [4]) 对 $x_i, x_j \in \mathcal{X}, x_i \neq x_j$ 且 $d_X(x_i, x_j) > 0$, 线索子集 S 的成对泄露定义为

$$\text{mPL}(x_i, x_j; S) = \frac{1}{d_X(x_i, x_j)} \left| \ln \frac{\Pr_\theta(X = x_i | I)}{\Pr_\theta(X = x_j | I)} - \ln \frac{\Pr_\theta(X = x_i | I \ominus S)}{\Pr_\theta(X = x_j | I \ominus S)} \right| \quad (2)$$

图像级泄露在容许对集合 P (两种发布下后验质量均为正的地点对)上聚合:

$$\text{mPL}(S) = \frac{1000}{|P|} \sum_{(i,j) \in P} \text{mPL}(x_i, x_j; S) \quad (3)$$

其中 $\Pr_{\theta}(\cdot | I)$ 为全视图信念、 $\Pr_{\theta}(\cdot | I \ominus S)$ 为反事实基线信念(遮蔽视图):mPL 度量二者间的距离归一化几率移动;系数 1000 将单位定为 nats/1000 km。绝对值使 mPL 与方向无关。注意 $v(N)$ (遮住全部已识别线索)并非整张图的总泄露——残余背景(气候、地形、道路布局)仍可定位; $v(N)$ 是已识别线索集的可移除总泄露。

2.3 校准与温度不变性

GeoRanker 得分是排序/距离奖励,非概率训练的对数似然,故 softmax 是信念而非校准后验。这一点重要,因为 mPL 随 τ 反比缩放:由于 s 在对数几率中相消,

$$p_i(\tau) = \frac{p_i(1)^{1/\tau}}{\sum_j p_j(1)^{1/\tau}}, \quad \text{mPL}(S; \tau) = \frac{1}{\tau} \text{mPL}(S; 1) \quad (4)$$

在数据上精确验证(如 $\tau = 0.5/2/5$ 时 mPL 分别 $\times 2.00/\times 0.50/\times 0.20$)。两点推论:(i) τ 是纯全局缩放,故图内的子集排序与交互符号——本文所有结论所依赖者——对 τ 严格不变,绝对量级以 $\tau = 1$ 为单位报告;(ii) 就绝对尺度而言,温度缩放可在留出集的真值 NLL 上拟合:47/48 划分下最优为 $\tau^* = 0.95$ (接近 1),测试 NLL 2.21 $\rightarrow$ 2.19、Brier 0.643 $\rightarrow$ 0.639,说明 $\tau = 1$ 已近最优。因此本文报告的是得分诱导的信念移动归因,而非严格的贝叶斯后验泄露保证。

3 不可加性:泄露作为集合函数

在线索子集上定义泄露集合函数:

$$v(S) = \text{mPL}(S), \quad v(\emptyset) = 0, \quad S \subseteq N = \{1, \dots, m\} \quad (5)$$

经验上 $v(S \cup T) \neq v(S) + v(T)$, 且两个方向都会出现。**备份(超可加)**:冗余线索互相补偿,单遮任何一条都有 $v(\{k\}) \approx 0$, 而 $v(N)$ 很大(冈崎祭典场景正是如此)。**重叠(次可加)**:携带重叠证据的线索各自单独就能造成大部分移动,故 $v(\{1, 2\}) < v(\{1\}) + v(\{2\})$ (卡普里照片中的石灰岩崖与岩石海岸线)。因此,没有任何单一遮蔽条件能给出公平的逐线索数值:leave-one-out 边际 $v(N) - v(N \setminus \{k\})$ 低估互为备份的线索,而 leave-one-in 值 $v(\{k\})$ 高估相互重叠的线索;在我们的实验中,两种读数最多相差一个数量级。

4 Shapley 归因

定义 4.1 (Shapley-mPL) 线索 k 的归因泄露为其在集合函数 v 下的 Shapley 值:

$$\varphi_k = \sum_{S \subseteq N \setminus \{k\}} \frac{|S|! (m - |S| - 1)!}{m!} [v(S \cup \{k\}) - v(S)] \quad (6)$$

φ_k 是在全部 $m!$ 种移除顺序下、移除线索 k 的平均边际破坏,也是唯一同时满足效率、对称、空线索与线性四条公理的分配。我们依赖的是效率公理:

$$\sum_{k=1}^m \varphi_k = v(N) \quad (7)$$

因此“线索 k 贡献了总泄露的 $\phi_k/v(N)$ ”是良定义的表述。对两线索图像(数据中的中位情形), 公式退化为 leave-one-in 与 leave-one-out 两种读数的平均:

$$\varphi_1 = \frac{1}{2}v(\{1\}) + \frac{1}{2}[v(\{1,2\}) - v(\{2\})] \quad (8)$$

成对结构由 Shapley 交互指数(SII)刻画,它在所有 coalition context 上平均二阶差分:

$$I_{kl}^{SII} = \sum_{S \subseteq N \setminus \{k,l\}} \frac{|S|!(m-|S|-2)!}{(m-1)!} [v(S \cup \{k,l\}) - v(S \cup \{k\}) - v(S \cup \{l\}) + v(S)] \quad (9)$$

$I^{SII} < 0$ 为重叠, > 0 为备份。算例(卡普里) $v(\{\text{崖}\}) = 0.088$ 、 $v(\{\text{海岸线}\}) = 0.104$ 、 $v(N) = 0.113$, 得 $\phi_{\text{崖}} = 0.049$ 、 $\phi_{\text{海岸线}} = 0.065$ (二者之和恰为 $v(N)$), $I = -0.079$ 正确标记两条海岸线索互相重叠。 ϕ_k 可以合法地为负(遮蔽 k 反而把信念推回原处),按实测值如实报告。

5 实验管线




图 1:实验管线。线索由 GPT-4o 命名、SAM 3 定位,按子集遮蔽后由 GeoRanker 后验估计器在度量空间上打分;全部子集上的 mPL 定义集合函数 v ,再由 Shapley 值归因至单条线索。

组件	选择
数据集	im2gps3k 子集, 100 张高清图像
线索命名	GPT-4o 定位推理(名称、类别、分割查询)
分割	SAM 3 文本到掩码;退化掩码(>40% 画幅)剔除
度量空间	138 个真值标签 + GPS, haversine; 2 km 别名去重(137 点)
攻击者	GeoRanker: Qwen2-VL-7B + LoRA + 价值头, nf4 量化, 确定性
信念引出	提示 = 图像 + 候选 GPS + 标签文本; softmax $\tau = 1$
度量	mPL(nats/1000 km), 图内可比;完整后验分布落盘
归因	Shapley ϕ + 交互指数 I (全部多线索图具备完整 2^m 子集格, $m \leq 5$)

表 1:实现摘要。

6 100 张图像上的结果

在 95 张含可遮线索的图像上, 攻击者的国家尺度精度(误差 < 750 km)为 77.9%, 25 km 内 45.3%, 中位误差 59 km(中位 $p_{\text{true}} = 0.137$)。归因在**全部 95 张**上计算(主结果);另将其分层为 71 张国家正确 / 24 张国家错误——top-1 错误并不意味着信念未移动(mPL 度量几率移动, 而非 top-1 是否正确)。




图 2: (a) 攻击者定位精度(误差阈值); (b) 对真值地点的置信; (c) 逐类别单线索 mPL(基线; 矫正归因见图 3)(中位数)。

逐类别泄露 作为传统消融基线, 原始单条遮蔽效应(中位 mPL, 全 95 张)把 text/signage 排在首位(0.136, n=29), 其后为 vehicles/plates 0.129 (12)、landmarks/buildings 0.123 (31)、environment 0.094 (78)、commercial/cultural 0.088 (42)、architecture 0.087 (41)、road/infrastructure 0.080 (10)。由 § 3 可知该量因对共享泄露重复计数而高估逐线索归因。**主结果是 Shapley 矫正后的排序(图 3a):** text/signage 0.080 > landmarks/buildings 0.072 > environment 0.060 > vehicles/plates 0.045 > architecture 0.042 > commercial/cultural 0.037 > road/infrastructure 0.034。矫正使每个中位数约减半并重排榜首:**vehicles/plates 从第 2(原始)降至第 4**——其表面独立重要性大多与同场景共现线索共享; 而 text/signage 仍居第 1, 即真正共享最少的泄露源。(若限制到 71 张国家正确图, 前二名顺序会变, 说明国家条件化本身是选择效应; 故以全 95 张为主集。)

Shapley 归因 对每张多线索图($m = 2 - 5$)枚举完整 2^m 子集格, 并纳入 $v(\{1\})$, 故全部 95 张均获得归因; 效率恒等式 $\sum \phi_k = v(N)$ 在 $m \geq 2$ 处精确成立。交互采用 § 4 的 Shapley 交互指数(在 coalition context 上平均), 而非 empty-context 二阶差分。在 239 对线索上(图 3b):




图 3: (a) 逐类别泄露, Shapley 矫正 vs 单条 mPL; (b) 239 对线索的 Shapley 交互结构。

交互类型	条件	线索对数	含义
重叠(次可加)	$SII < -0.01$	182	单遮任一条已完成大部分移动
$\approx$ 可加	$ SII \leq 0.01$	34	独立贡献
备份(超可加)	$SII > 0.01$	23	须同时遮蔽才见移动

表 2: 239 对线索的 Shapley 交互结构(全部可遮图; 中位 $SII = -0.028$)。empty-context 二阶差分会夸大重叠 (215/12/12)。

按正式 SII , 重叠占多数 (182/239, 76%), 表明单条 mPL 会对共享泄露重复计数, 从而高估逐线索归因; Shapley 将共享质量重新分配, 使各线索贡献之和恰等于 $v(N)$ 。(在 23 对备份线索 $SII > 0$ 中, 单条值反向低估贡献——注意正式 SII 揭示的备份对约为 empty-context 的两倍, 后者在满上下文下把它们掩盖了。) 极端案例: 布莱德湖是最强备份对 (湖心教堂 + 群山); 最强重叠对均为“建筑 $\times$ 植被”组合。231 条线索中仅 2 条 $\phi < -0.01$ 。

参考文献

[1] L. S. Shapley. A Value for n-Person Games. 1953.

[2] P. Jia, S. Park, S. Gao, X. Zhao, Y. Li. GeoRanker: Distance-Aware Ranking for Worldwide Image Geolocalization. NeurIPS 2025.

[3] Meta AI. SAM 3: Segment Anything with Concepts. 2025.

[4] Chen et al. Metric-normalized posterior leakage (mPL). 2026. (完整引文见配套 proposal。)